

Lucrarea 1: Testarea perceptronului

### Generarea de date pentru efectuarea exercitiilor

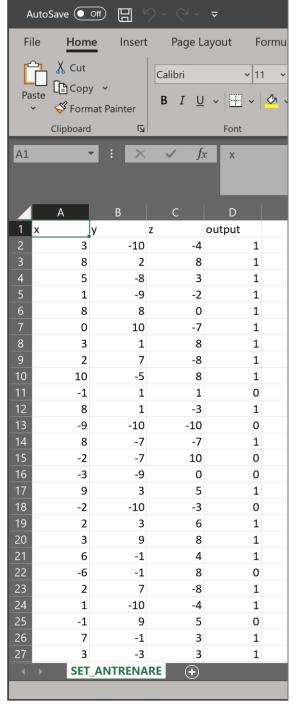
Folositi Excelul ca sa creati fisiere csv. Incepeti prin a va crea capul de tabel. In exemplul de aici am creat x, y, z, output.

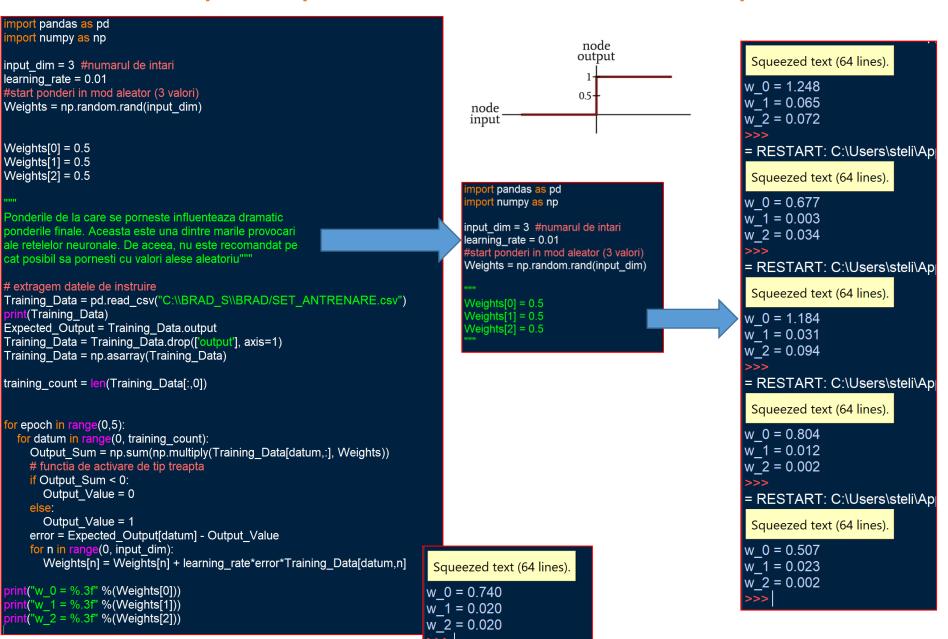
Intrati in prima caseta A2 si =RANDBETWEEN(val1,val2). Aici am creat valori aleatorii intre val1=-10 si val2=10, de tip intreg. Faceti lucrul respectiv pentru toate coloanele de intrare.

Pentru coloana de iesire creati conditia in functie de reguli ale intrarilor. Aici am creat conditia ca iesirea sa fie 0 pentru orice set de intrare in care x<0 (=IF(A2<0, 0,1)).

Pentru a va exersa puteti sa creati orice date de intrare si iesire, reale, intregi sau de tip string. Consultati MS Excel pentru detalii pe acest subiect.

In practica operam cu date reale.





Se observa ca ponderile finale ale nodurilor din retea sunt influentate de setul de valori de start.

Rata de învățare (learning rate) influențează rata la care învață reteaua neuronală.

Se antrenează o rețea neuronală oferind date de instruire și efectuând o procedură de instruire. În timp ce acest lucru se întâmplă, rețeaua învață - sau mai precis, învață să aproximeze relația intrare-ieșire conținută în datele de instruire.

Manifestarea învățării este modificarea greutății (ponderii), iar rata de învățare afectează modul în care greutățile sunt modificate.

```
port pandas as pd
  nport numpy as np
input_dim = 3 #numarul de intari
learning rate = 0.01
                                                                              Initializam o lista
Weights = [0 for x in range(input dim)]
Weights[0] = 0.5
Weights[1] = 0.5
Weights[2] = 0.5
                                                                                                 Cresterea numarului de
# extragem datele de instruire
Training Data = pd.read csv("C:\\BRAD S\\BRAD/SET ANTRENARE.csv")
Expected Output = Training Data.output
                                                                                                 epoci nu va duce la rezultate
Training Data = Training Data.drop(['output'], axis=1)
Training Data = np.asarray(Training Data)
                                                                                                 mai bune. Totul depinde de
training_count = <mark>len</mark>(Training_Data[:,0])
                                                                                                  acuratete.
# nunmar de date pe prima coloana
 orint("Numarul de elemente in lista de instruire este", training count)
 #punem numarul de epoci la 100
                                                                                Antrenam reteaua
  or epoch in range(0,5):
  for datum in range(0, training_count):
    Output Sum = np.sum(np.multiply(Training Data[datum.:], Weights))
    # functia de activare de tip treapta
    if Output Sum < 0:
                                                                                       Aici am folosit
       Output Value = 0
                                                                                        doar 5 iteratii
       Output Value = 1
    error = Expected Output[datum] - Output Value
    for n in range(0, input dim):
                                                                                        (epoci) pentru
      Weights[n] = Weights[n] + learning rate*error*Training Data[datum,n]
                                                                                        antrenare
  <mark>int("w_0 = %.3f" %(Weights[0]))</mark>
  int("w 1 = \%.3f" \%(Weights[1]))
  rint("w 2 = %.3f" %(Weights[2]))
                                                                                Testam reteaua
 def aplicare(d intrare):
  element = 0
  for i in range(0,input_dim):
    element = element + d intrare[i]*Weights[i]
  # functia de activare
                                                                Numarul de elemente in lista de instruire este 66
  if element <0:
                                                                w 0 = 0.740
    iesire=0
                                                                w 1 = 0.020
                                                                w 2 = 0.020
  print("Pentru intrarea", d intrare, ", iesirea este", iesire)
                                                                Pentru intrarea [2, -5, 8], iesirea este 1
                                                                Pentru intrarea [-3, 4, -2], iesirea este 0
intrare1 = [2, -5, 8]
intrare2 =[-3,4,-2]
                                                                 >>>
aplicare(intrare1)
aplicare(intrare2)
```

```
Numar epoci 100

w_0 = 1.370

w_1 = 0.010

w_2 = 0.150

Pentru intrarea [2, -5, 8], iesirea este 1

Pentru intrarea [-3, 4, -2], iesirea este 0

>>>

te

Numarul de elemente in lista de instruire este 66

Numar epoci 1000

w_0 = 2.230

w_1 = 0.050

w_2 = 0.100

Pentru intrarea [2, -5, 8], iesirea este 1

Pentru intrarea [-3, 4, -2], iesirea este 0

>>>
```

Numarul de elemente in lista de instruire este 66

```
Numarul de elemente in lista de instruire este 66
Numar epoci 10000
w_0 = 2.230
w_1 = 0.050
w_2 = 0.140
Pentru intrarea [2, -5, 8], iesirea este 1
Pentru intrarea [-3, 4, -2], iesirea este 0
>>>
```

```
Numarul de elemente in lista de instruire este 66

Numar epoci 100000

w_0 = 2.230

w_1 = 0.050

w_2 = 0.120

Pentru intrarea [2, -5, 8], iesirea este 1

Pentru intrarea [-3, 4, -2], iesirea este 0
```

```
Numarul de elemente in lista de instruire este 66

Numar epoci 100

w_0 = 1.370

w_1 = 0.010

w_2 = 0.150

Pentru intrarea [2, -5, 8], iesirea este 1

Pentru intrarea [-3, 4, -2], iesirea este 0

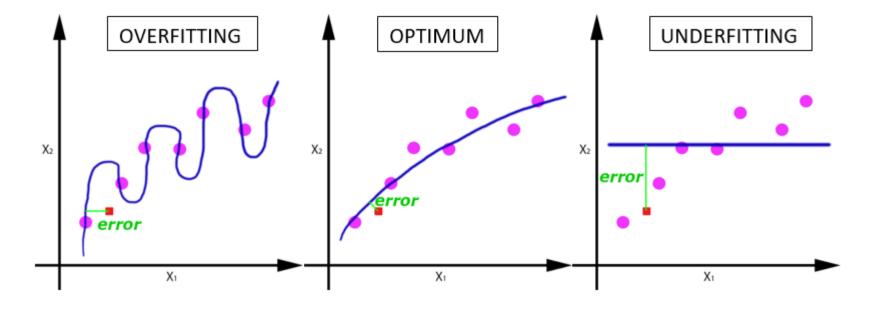
Pentru intrarea [-20, -20, 11], iesirea este 0

Pentru intrarea [-200, 20000, 1], iesirea este 0

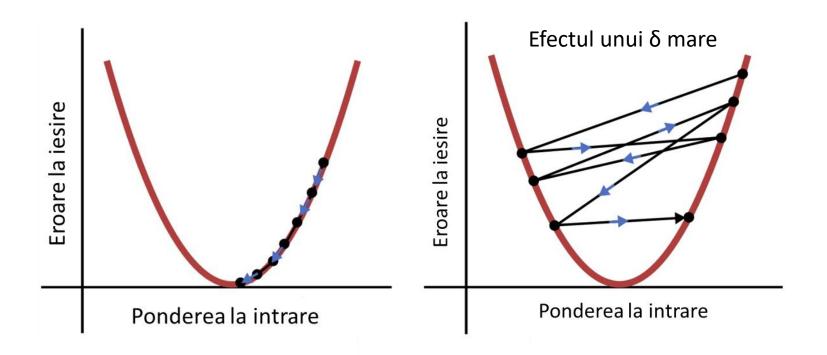
Pentru intrarea [-200, 200000, 10000], iesirea este 1

>>>
```

Observam ca atunci cand datele de intrare difera semnificativ de setul de antrenare, reteua da un rezultat eronat



Numarul neadecvat de epoci poate conduce la diverse situatii, cum ar fi "overfitting"-ul, adica sa propui un model care nu este suficient de robust la un set mai divers de date de intrare.



Prin rata de invatare facem practic "salturi" in modificarea ponderilor. Scoup final este ca sa ajungem la eroarea minima. In functie de valoarea ratei de invatare "salturile" difera. Trebuie evitat cazul in care sarim peste minimul global. Nu exista o regula dupa care se allege rata de invatare! Nu exista inca nici o regula pentru a identifica rata de invatare optima pentru o aplicatie particulara! Totul se bazeaza pe intuitie si experienta. De aceea, setarea retelelor neuronale trebuie sa implice experti in domeniul de aplicare, nu programatori.

Regula de invatare:

$$w_{nou} = w + (\alpha \times \delta \times input)$$

- α este rata de învățare
- δ este diferenţa dintre rezultatul aşteptat şi rezultatul calculat (adică eroarea)

De fiecare dată când aplicăm regula de învățare, greutatea sare într-un punct nou pe curba de eroare. Dacă δ este mare, aceste salturi ar putea fi, de asemenea, destul de mari și este posibil ca rețeaua să nu se antreneze eficient, deoarece greutățile nu converg treptat către erori minime. În schimb, salturile devin haotice.

#### Exercitiu individual

Repetati aplicatia pentru alte functii de activare si trageti concluzii. Folositi pe rand functiile de activare: sigmoid si ReLU.

**Optional**: studiati codul atasat.

```
# Make a prediction with weights
def predict(row, weights):
          activation = weights[0]
          for i in range(len(row)-1):
                    activation += weights[i + 1] * row[i]
          return 1.0 if activation >= 0.0 else 0.0
# Estimate Perceptron weights using stochastic gradient descent
def train weights(train, I rate, n epoch):
          weights = [0.0 for i in range(len(train[0]))]
          for epoch in range(n_epoch):
                    sum error = 0.0
                    for row in train:
                               prediction = predict(row, weights)
                               error = row[-1] - prediction
                               sum error += error**2
                               weights[0] = weights[0] + I_rate * error
                               for i in range(len(row)-1):
                                         weights[i + 1] = weights[i + 1] + I_rate * error * row[i]
                    print('>epoch=%d, Irate=%.3f, error=%.3f' % (epoch, I rate, sum error))
          return weights
```

# perceptron\_src.py

```
test predictions
dataset = [[2.7810836,2.550537003,0],
          [1.465489372,2.362125076,0],
          [3.396561688,4.400293529,0],
          [1.38807019,1.850220317,0],
          [3.06407232,3.005305973,0]
          [7.627531214,2.759262235,1]
          [5.332441248,2.088626775,1],
          [6.922596716,1.77106367,1]
          [8.675418651,-0.242068655,1]
          [7.673756466.3.508563011.1]]
weights = [-0.1, 0.20653640140000007, -0.23418117710000003]
for row in dataset:
          prediction = predict(row, weights)
          print("Expected=%d, Predicted=%d" % (row[-1], prediction))
# Calculate weights
                                                      = RESTART: C:\Users\steli\AppData\Local\Programs\P
dataset = [[2.7810836,2.550537003,0],
                                                      Expected=0, Predicted=0
                                                      Expected=0, Predicted=0
          [1.465489372,2.362125076,0],
                                                      Expected=0. Predicted=0
          [3.396561688,4.400293529,0],
                                                      Expected=0. Predicted=0
          [1.38807019,1.850220317,0],
                                                      Expected=0, Predicted=0
          [3.06407232,3.005305973,0],
                                                      Expected=1, Predicted=1
          [7.627531214,2.759262235,1],
                                                      Expected=1, Predicted=1
          [5.332441248,2.088626775,1],
                                                      Expected=1, Predicted=1
          [6.922596716,1.77106367,1],
                                                      Expected=1, Predicted=1
                                                      >epoch=0, Irate=0.100, error=2.000
          [8.675418651,-0.242068655,1],
                                                      >epoch=1, Irate=0.100, error=1.000
          [7.673756466,3.508563011,1]]
                                                      >epoch=2. lrate=0.100. error=0.000
 rate = 0.1
                                                      >epoch=3, Irate=0.100, error=0.000
                                                     >epoch=4, Irate=0.100, error=0.000
n = 5
                                                      [-0.1, 0.20653640140000007, -0.23418117710000003]
weights = train weights(dataset, I rate, n epoch)
print(weights)
```

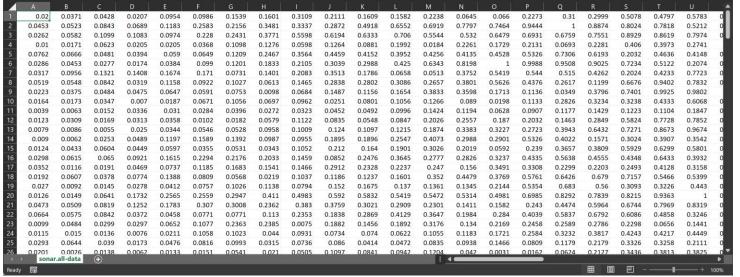
## Studiu individual (optional)

Deschideti fisierele intr-un mediu compatibil cu scripturile Python.

```
perceptron_sk.py
perceptron_sonar.py
```

Pentru a doua aplicatie utilizati fisierul cu date: sonar.all-data.csv

Studiati codul si logica aplicatiei. Trageti concluzii.



```
perceptron_sk.py - C:\Users\steli\AppData\Local\Programs\Python\Python37\pe.
     Edit Format Run Options Window
 # evaluate a perceptron model on the dataset
 rom numpy import mean
 rom numpy import std
  om sklearn.datasets import make classification
 rom sklearn.model selection import cross val score
 rom sklearn.model selection import RepeatedStratifiedKFold
  om sklearn.linear_model import Perceptron
# define dataset
X, y = make classification(n samples=1000, n features=10, n informative=10, n redundant=0, rando
model = Perceptron()
# define model evaluation method
cv = RepeatedStratifiedKFold(n splits=10, n repeats=3, random state=1)
scores = cross_val_score(model, X, y, scoring='accuracy', cv=cv, n_jobs=-1)
# summarize result
 orint('Mean Accuracy: %.3f (%.3f)' % (mean(scores), std(scores)))
# make a prediction with a perceptron model on the dataset
 rom sklearn.datasets import make_classification
 rom sklearn.linear model import Perceptron
# define dataset
X, y = make_classification(n_samples=1000, n_features=10, n_informative=10, n_redundant=0, rand
model = Perceptron()
model.fit(X, y)
row = [0.12777556.-3.64400522.-2.23268854.-1.82114386.1.75466361.0.1243966.1.03397657.2.35
 # make a prediction
yhat = model.predict([row])
# summarize prediction
 rint('Predicted Class: %d' % yhat)
# grid search learning rate for the perceptron
 rom sklearn.datasets import make classification
 rom sklearn.model selection import GridSearchCV
 rom sklearn.model selection import RepeatedStratifiedKFold
 rom sklearn.linear model import Perceptron
# define dataset
                                                                                           Ln: 1 Col: 0
```

## Studiu individual: backpropagation – exemplificare cod Python

